

PROJET : Système RAG pour Recherche Documentaire Interne

CLIENT : Telnet Holding

SECTEUR : Industrie / Télécommunications

DURÉE : 8 mois (2023 - 2024)

BUDGET : 350 000 TND

ÉQUIPE : 3 data scientists, 2 développeurs, 1 chef de projet

CONTEXTE

Telnet Holding disposait de 100 000+ documents internes (rapports techniques, brevets, documentation produit, emails) dispersés dans différents systèmes. Les équipes perdaient un temps considérable à chercher des informations. Il fallait un système de recherche intelligent capable de comprendre le langage naturel.

SOLUTION OLIVESOFT

- Système RAG (Retrieval-Augmented Generation) avec pgvector
- Embeddings via Ollama (nomic-embed-text) pour la confidentialité
- Interface de recherche en langage naturel
- Génération de réponses contextuelles avec LLM open-source (Llama 3.1)
- Déploiement on-premise pour respecter la confidentialité des données

TECHNOLOGIES

- Backend : FastAPI, Python 3.11
- LLM : Ollama (Llama 3.1 8B), nomic-embed-text
- Base vectorielle : PostgreSQL + pgvector
- Frontend : React, Tailwind CSS
- Infrastructure : Docker, Kubernetes on-premise

RÉSULTATS

- Réduction de 70% du temps de recherche d'informations
- 95% de précision sur les recherches documentaires (benchmark interne)
- 100% des données restent on-premise (conformité RGPD)
- Adoption par 200+ collaborateurs dans les 2 premiers mois

COMPÉTENCES MOBILISÉES

- Architecture RAG et recherche vectorielle
- Intégration d'LLMs open-source (Ollama)
- Développement FastAPI
- Déploiement on-premise et confidentialité des données
- Optimisation des embeddings et du retrieval